#### **Digital**House>

#### **DATA SCIENCE**

Machine Learning – Modelos em Produção

## PERSISTÊNCIA DE MODELOS

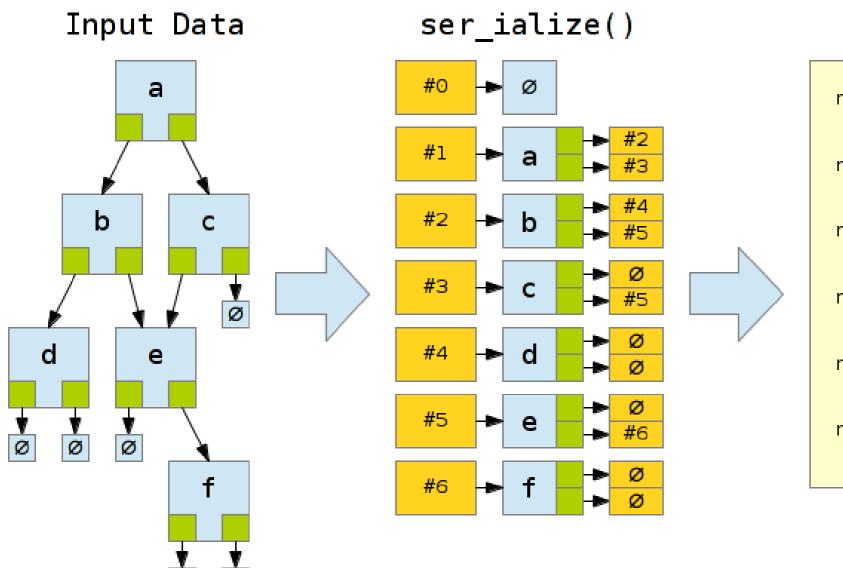




https://docs.python.org/3/library/pickle.html

O Pickle é uma biblioteca de SERIALIZAÇÃO de objetos do Python. Pode ser utilizado para gravar estruturas de dados, modelos preditivos, etc

#### SERIALIZAÇÃO DE DADOS



#### Output Format

```
node #1 { letter 'a';
   left #2; right #3; }

node #2 { letter 'b';
   left #4; right #5; }

node #3 { letter 'c';
   left #5; right NULL; }

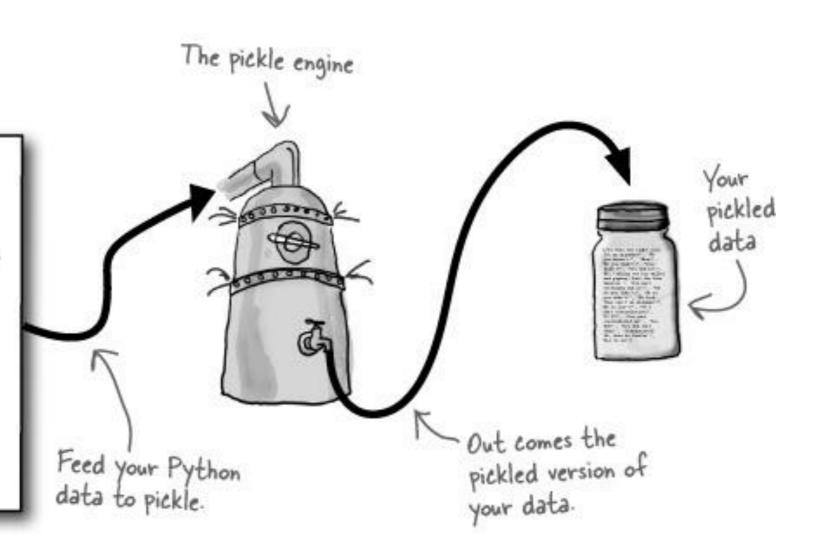
node #4 { letter 'd';
   left NULL; right NULL; }

node #5 { letter 'e';
   left NULL; right #6; }

node #6 { letter 'f';
   left NULL; right NULL; }
```

Your data as it appears in Python's memory

['Is this the right room for an argument?', "No you haven't!", 'When?', "No you didn't!", "You didn't!", 'You didn't!", 'You did not!', 'Ah! (taking out his wallet and paying) Just the five minutes.', 'You most certainly did not!', "Oh no you didn't!", "Oh no you didn't!", "Oh look, this isn't an argument!", "No it isn't!", "It's just contradiction!", 'It IS!', 'You just contradicted me!', 'You DID!', 'You did just then!', '(exasperated) Oh, this is futile!!', 'Yes it is!']



https://www.oreilly.com/library/view/head-first-python/9781449397524/ch04.html





pickle exploitation



TL;DR: Never unpickle data from sources you don't trust. Otherwise you open your app up to a relatively simple way of remote code execution.

intoli	HOME	FEATURES	PRICING	TEAM	BLOG	CONTACT	
DANGEROUS PICKLES - MALICIOUS PY	ТНОМ	N SERIA	ALIZA	TION			
		OCTOBER 17	205	EARCH			
What's so dangerous about pickles?				Search AGS		Q	
Those pickles are very dangerous pickles. I literally can't begin to tell you how really dangerous they are. You have to trust me on that. It's important, Ok?				<b>≫</b> PYTHON (19)			
"Explosive Disorder" by Pan Telare  Before we get elbow deep in opcodes here, let's cover a little background. The Python standard library	has a mod	ule called pickle 1	hat is	<b>\$</b> BROWS	E ALL TAG	SS	

## Joblib: running Python functions as pipeline jobs

#### Introduction



- 1. transparent disk-caching of functions and lazy re-evaluation (memoize pattern)
- 2. easy simple parallel computing

Joblib is optimized to be **fast** and **robust** on large data in particular and has specific optimizations for *numpy* arrays. It is **BSD-licensed**.

Documentation:	https://joblib.readthedocs.io
Download:	https://pypi.python.org/pypi/joblib#downloads
Source code:	https://github.com/joblib/joblib
Report issues:	https://github.com/joblib/joblib/issues

https://joblib.readthedocs.io/en/latest/

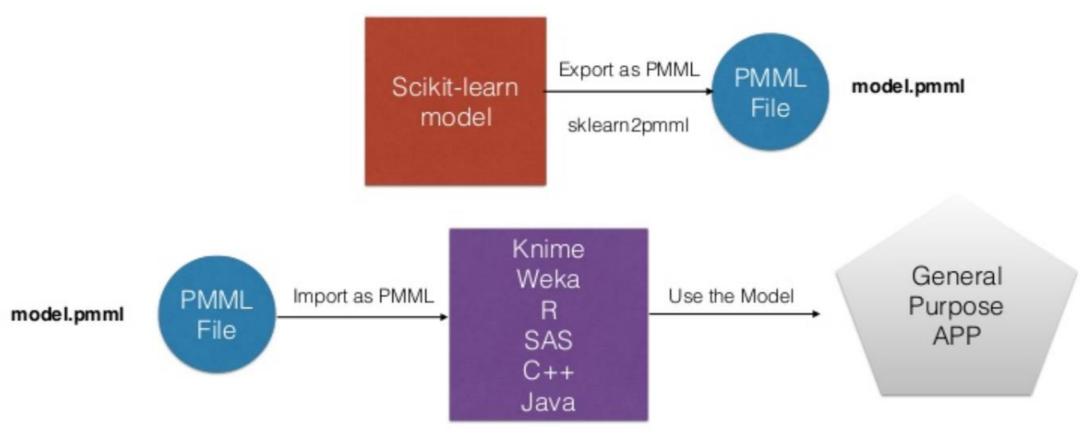
O Joblib também oferece funcionalidades de persistência e serialização de dados, além de ser excelente para a paralelização de tarefas e montagem de pipelines complexos.



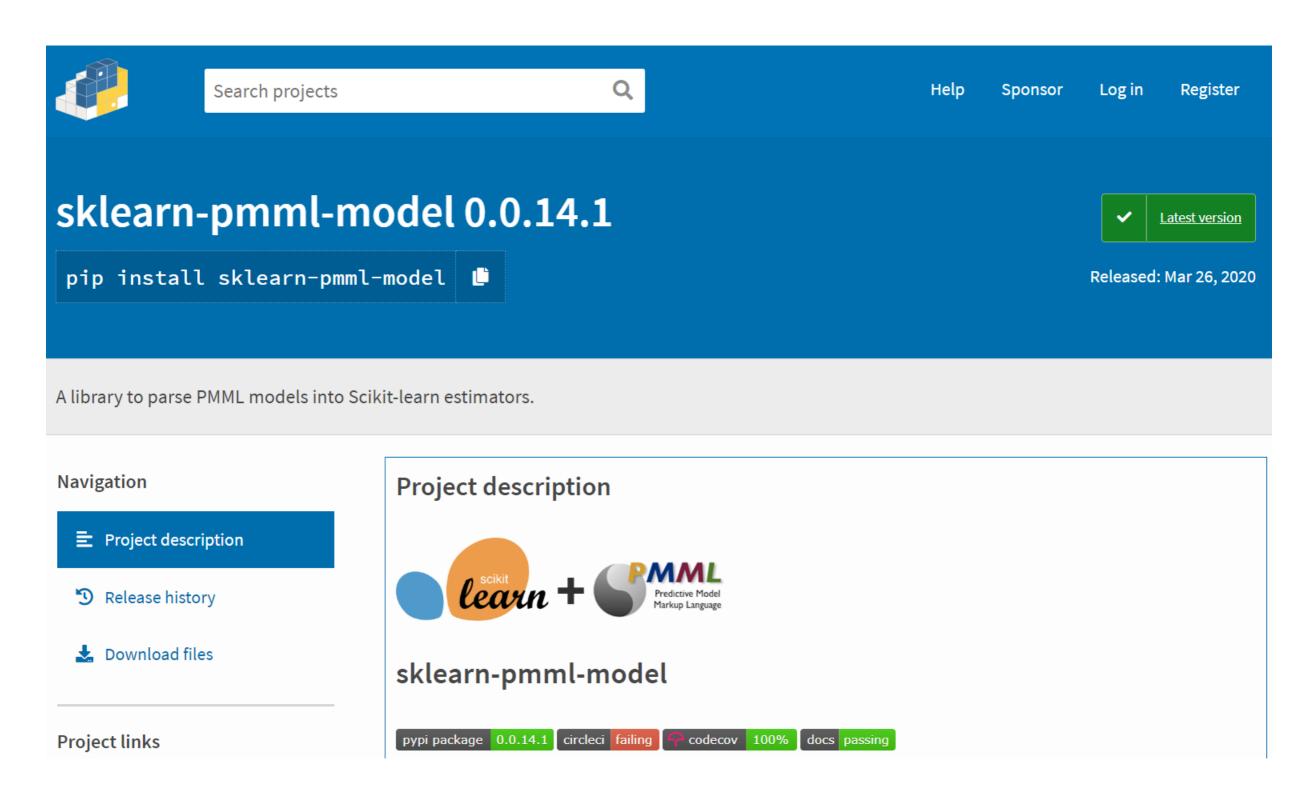
### Pmml XML File

```
<Node recordCount="0" score="Iris-virginica">@R
      <True/>ORF
      <ScoreDistribution confidence="0.333333333333333" recordCount="50" value="Iris-virginica"/>ERES
      <ScoreDistribution confidence="0.333333333333333" recordCount="50" value="Iris-setosa"/> COMPAGE | CONTROL | CONTROL
      <ScoreDistribution confidence="0.3333333333333333" recordCount="50" value="Iris-versicolor"/>ERMIS
      <Node recordCount="0" score="Iris-virginica">@N#3
             <SimplePredicate field="a3" operator="greaterThan" value="2.450"/>GREE
             <ScoreDistribution confidence="0.5" recordCount="50" value="Iris-virginica"/>GRID
             <ScoreDistribution confidence="0.0" recordCount="0" value="Iris-setosa"/> GRIGG
             <ScoreDistribution confidence="0.5" recordCount="50" value="Iris-versicolor"/> GRIGG
             <Node recordCount="34" score="Iris-virginica">@@###
                    <SimpleFredicate field="a3" operator="greaterThan" value="5.150"/>CRM3
                   <ScoreDistribution confidence="1.0" recordCount="34" value="Iris-virginica"/>GRIG
                   <ScoreDistribution confidence="0.0" recordCount="0" value="Iris-setosa"/>GRIGG
                   <ScoreDistribution confidence="0.0" recordCount="0" value="Iris-versicolor"/>GRIE
             </Node>
             <Node recordCount="0" score="Iris-versicolor">@Nife
                    <SimplePredicate field="a3" operator="lessOrEqual" value="5.150"/>@RM3
                    <ScoreDistribution confidence="0.242424242424243" recordCount="16" value="Iris-virginica"/>COUNTED
                   <ScoreDistribution confidence="0.0" recordCount="0" value="Iris-setosa"/>
                   <ScoreDistribution confidence="0.757575757575757576" recordCount="50" value="Iris-versicolor"/>COUNTED
                   <Node recordCount="8" score="Iris-virginica">@RIGG
                          <SimplePredicate field="a4" operator="greaterThan" value="1.850"/>@New
                          <ScoreDistribution confidence="1.0" recordCount="8" value="Iris-virginica"/> (ScoreDistribution confidence="1.0" recordCount="8" value="1.0" value="1.0" recordCount="8" value="1.0" value="1.0" value="1.0" value="1.0" value="1.0" value="1.0" value="1.0" value="1.0" value="1.0" value
```

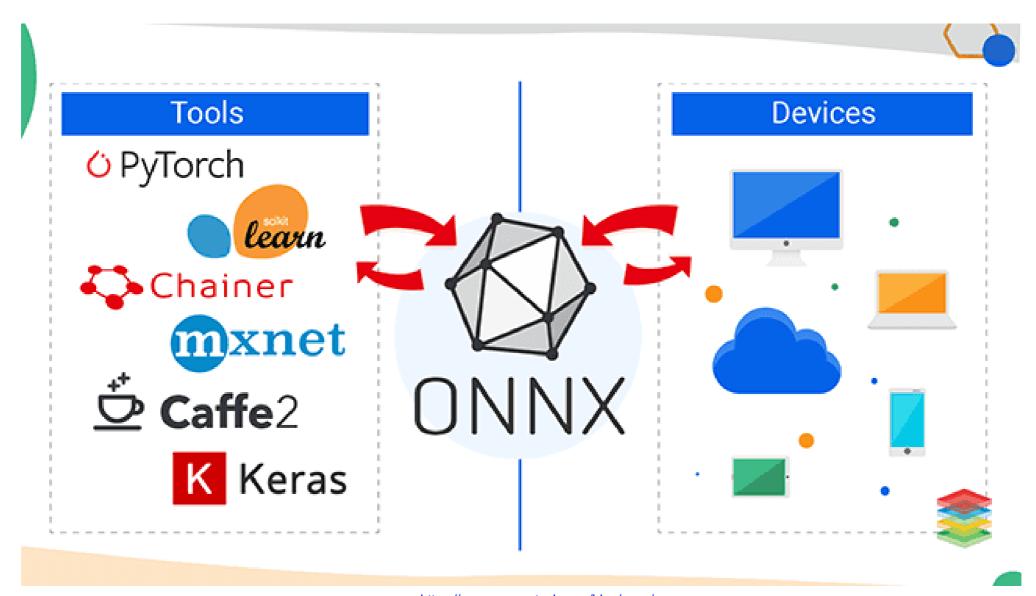
## PMML Pipeline



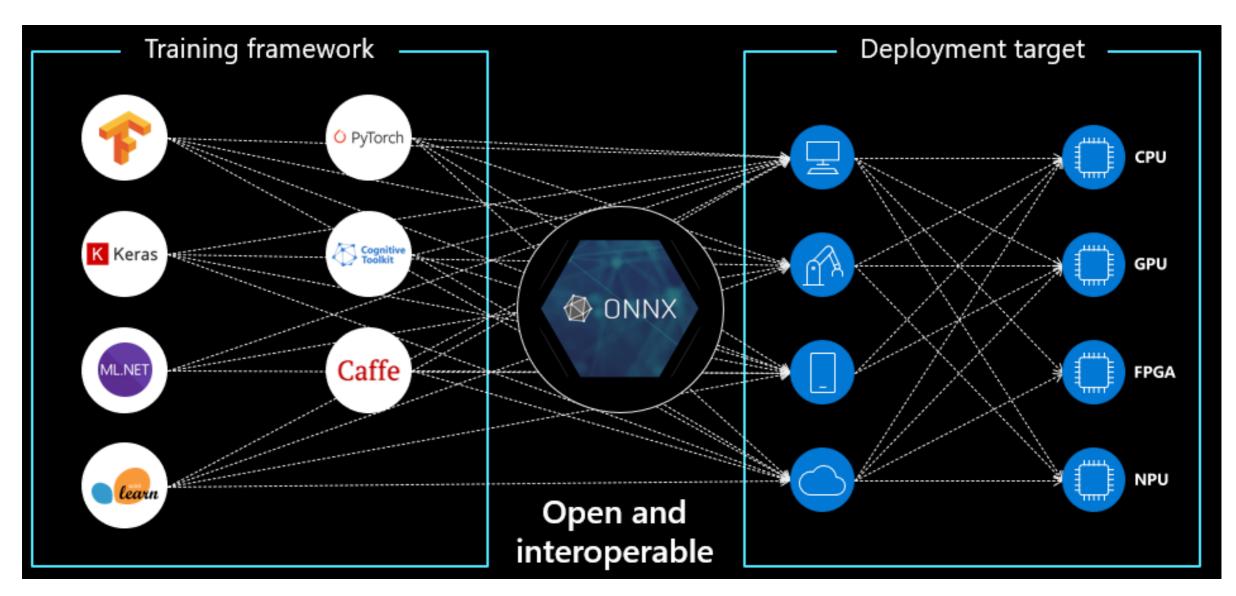
https://www.slideshare.net/AnassBensrhirDatasci/deploying-machine-learning-models-to-production



https://pypi.org/project/sklearn-pmml-model/



https://www.xenonstack.com/blog/onnx/



https://microsoft.github.io/ai-at-edge/docs/onnx/





Vamos rodar o o Notebook
 SklearnPipelines\_persistence\_vf.ipynb
 para vermos o Pickle e Joblib em ação.

# VAMOS COLOCAR UM WEB APP EM PRODUÇÃO (NA INTERNET)



# Streamlit. The fastest way to build data apps

Streamlit's open-source app framework is the easiest way for data scientists and machine learning engineers to create beautiful, performant apps in only a few hours! All in pure Python. All for free.

https://www.streamlit.io/

#### pip install streamlit



Observação – poderá ser necessário colocar o caminho do streamlit.exe no PATH (Windows)

C:\Users\[USUÁRIO]\AppData\Roaming\Python\Python37\Scripts

```
(base) C:\streamlit>streamlit hello

Welcome to Streamlit. Check out our demo in your browser.

Local URL: http://localhost:8501
Network URL: http://192.168.0.10:8501

Ready to create your own Python apps super quickly?
Just head over to https://docs.streamlit.io

May you create awesome apps!
```

Vamos rodar o "Hello World" do Streamlit no prompt e ver o resultado no Browser:

- > streamlit hello Depois iremos rodar também:
- > streamlit run tutorial.py
- > streamlit run bandrec-streamlit.py





#### Recomendação de Bandas

Escolha o país					

Digite o nome da Banda / Artista

megadeth

Submeter

#### Recommendations for megadeth:

1: black sabbath, with distance of 0.3221987029536757:

2: koЯn, with distance of 0.3742111519629977:

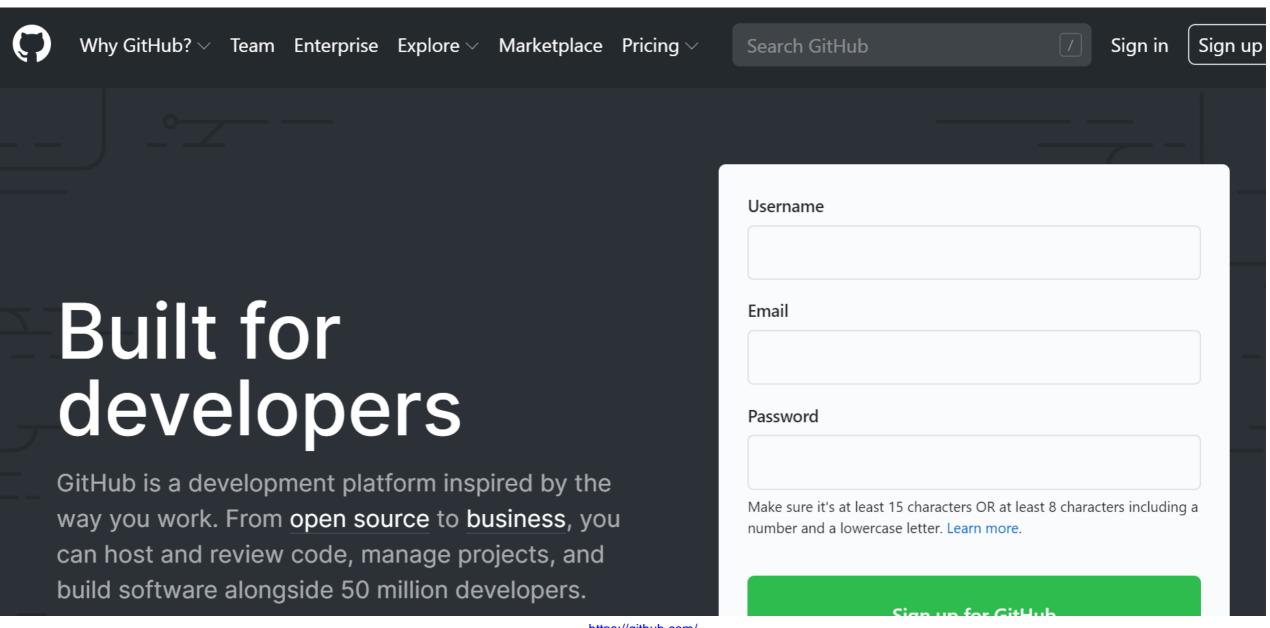
3: slipknot, with distance of 0.37701311363710077:



Descompactar arquivos recebidos do pacote webapp.zip



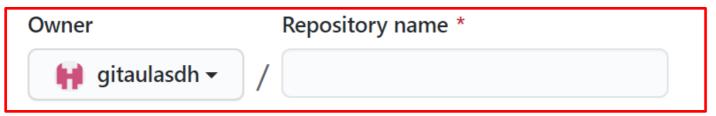
#### PASSO 1 – CRIAR UMA CONTA NO GITHUB



https://github.com/

#### Create a new repository

A repository contains all project files, including the revision history. Already have a project repository elsewhere? Import a repository.



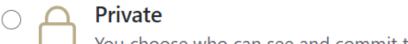
Great repository names are short and memorable. Need inspiration? How about ubiquitous-pancake?

Description (optional)



Public

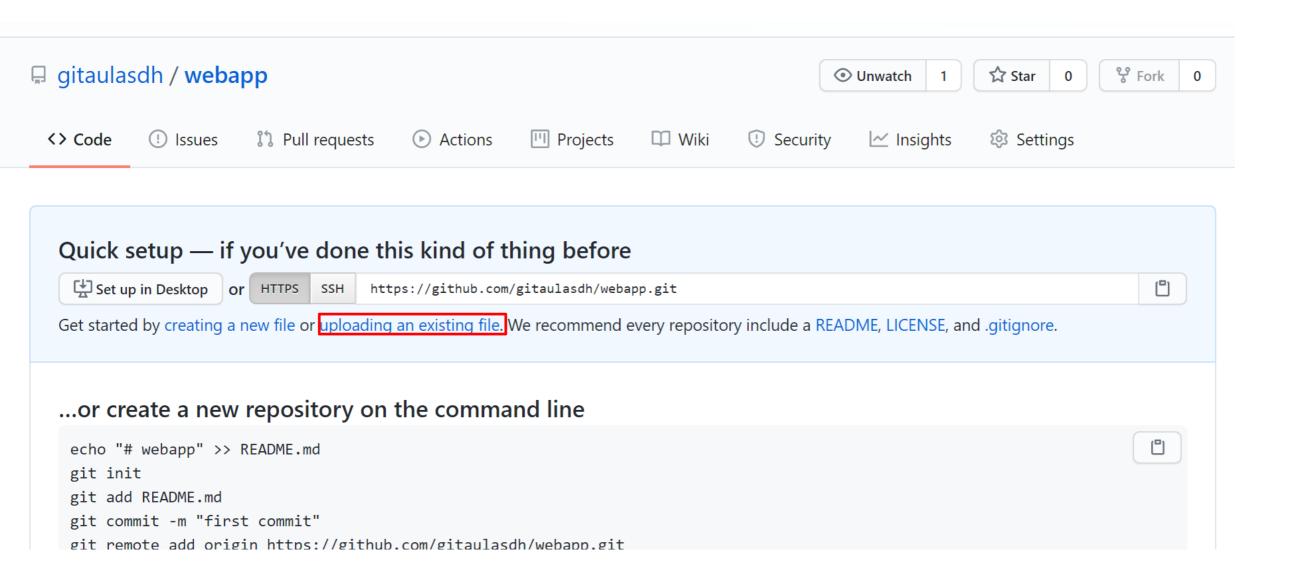
Anyone on the internet can see this repository. You choose who can commit.

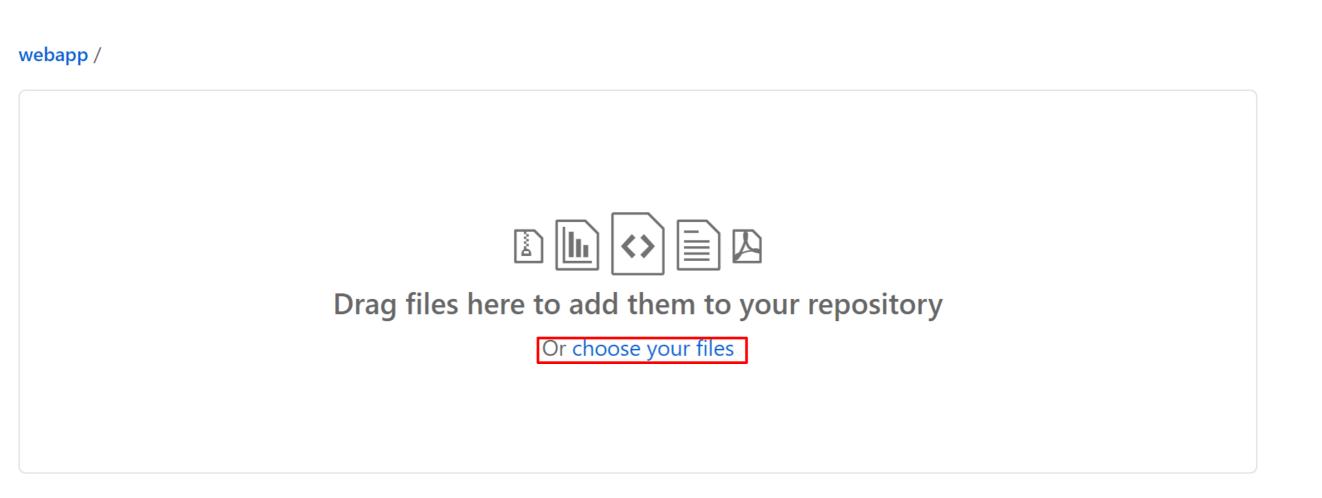


You choose who can see and commit to this repository.

Create repository

#### CRIAR NOVO REPOSITÓRIO

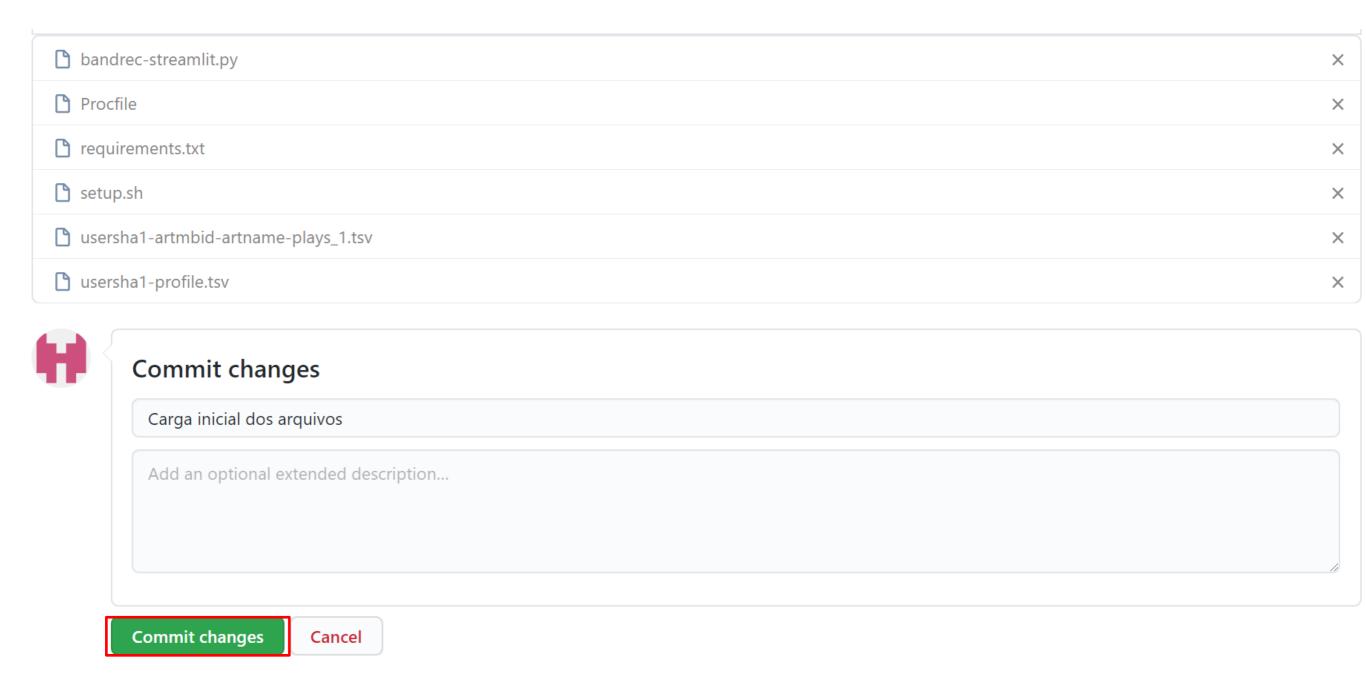




Subir todos arquivos que estavam no webapp.zip, descompactados previamente

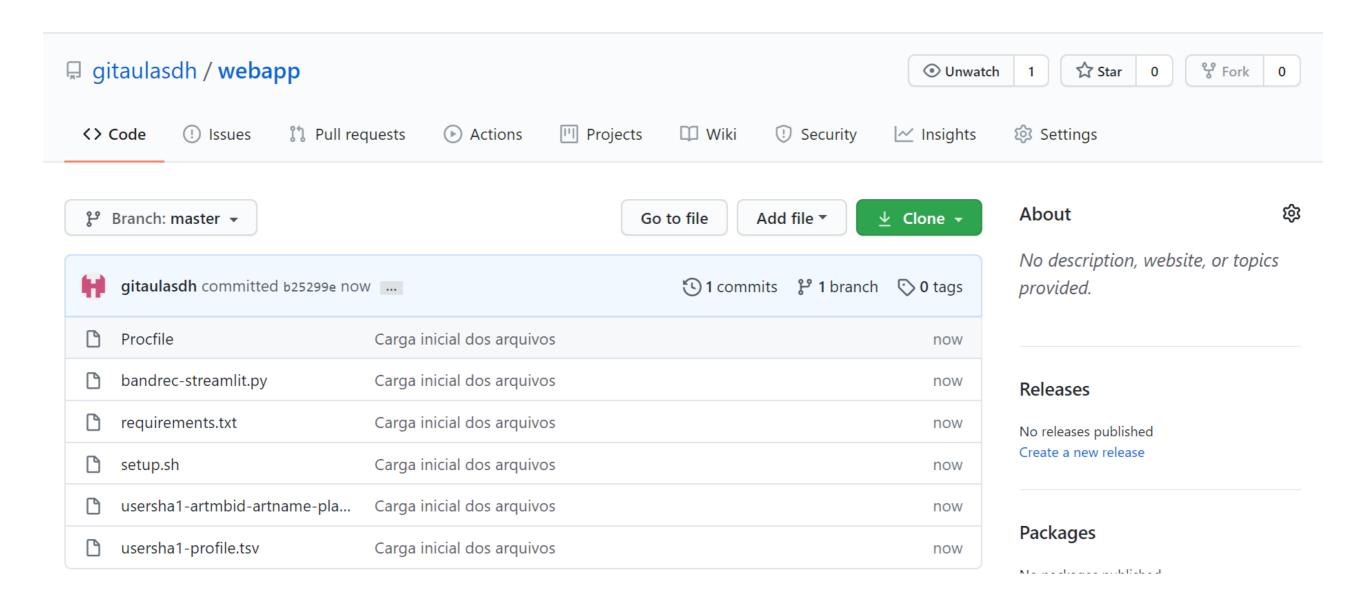


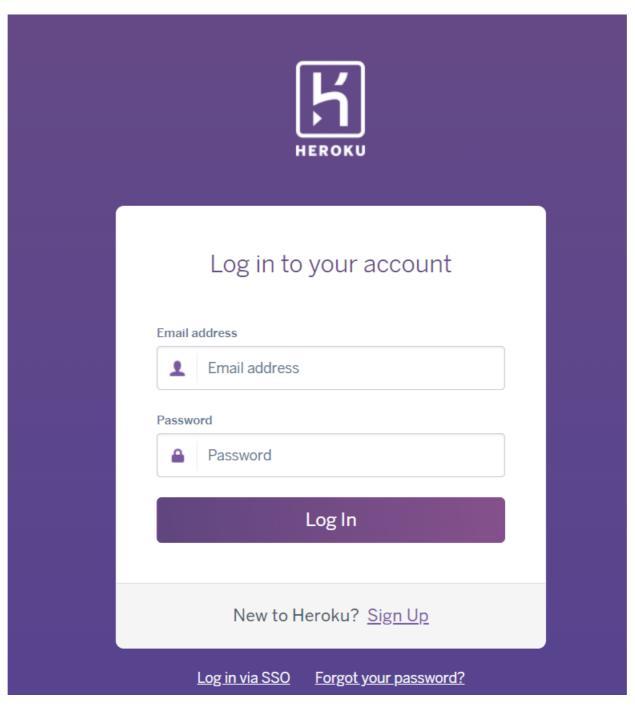
#### **COMMIT CHANGES!**



E nesta mesma tela dar "commit changes".

#### **REPOSITÓRIO CRIADO!**

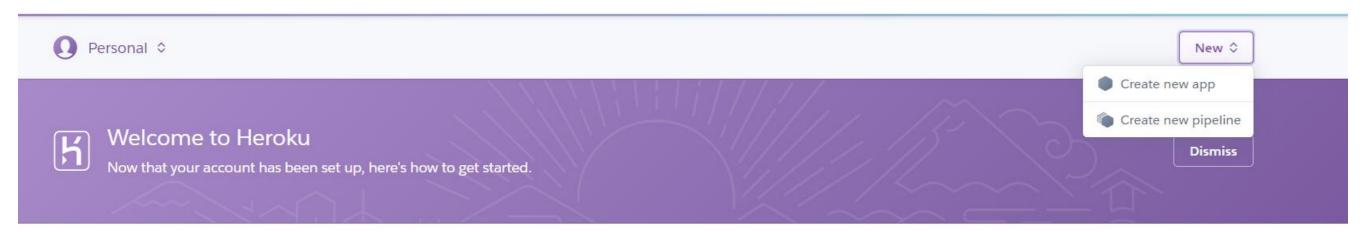


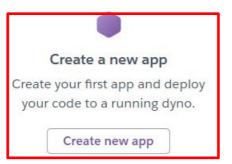


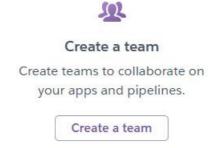
https://www.heroku.com/

Selecionar "Sign Up", preencher todos os dados e confirmar a inscrição no e-mail enviado

#### **CREATE A NEW APP**







#### Looking for help getting started with your language?

Get started by reading one of our language guides in the Dev Center











Python



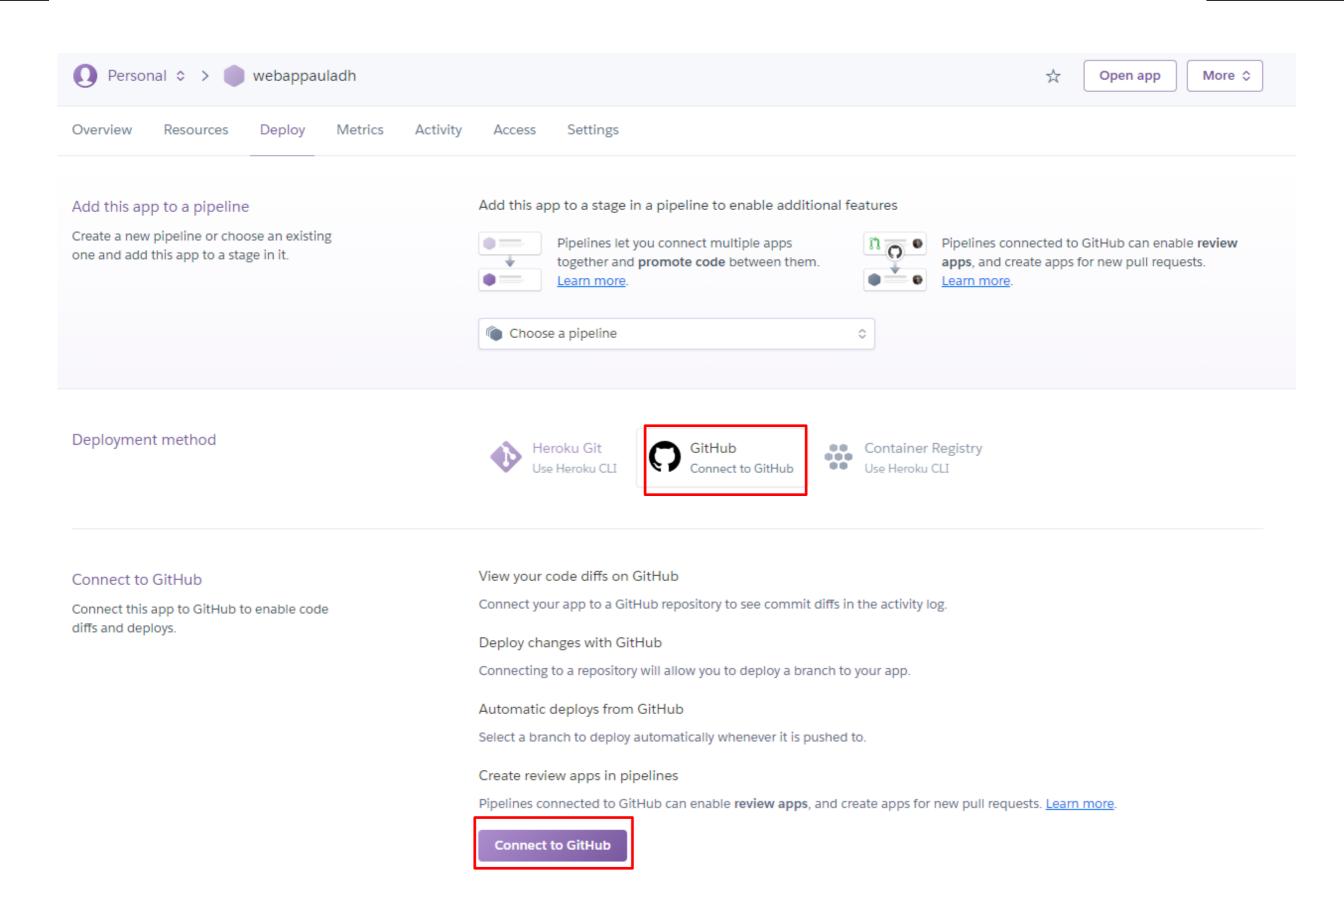




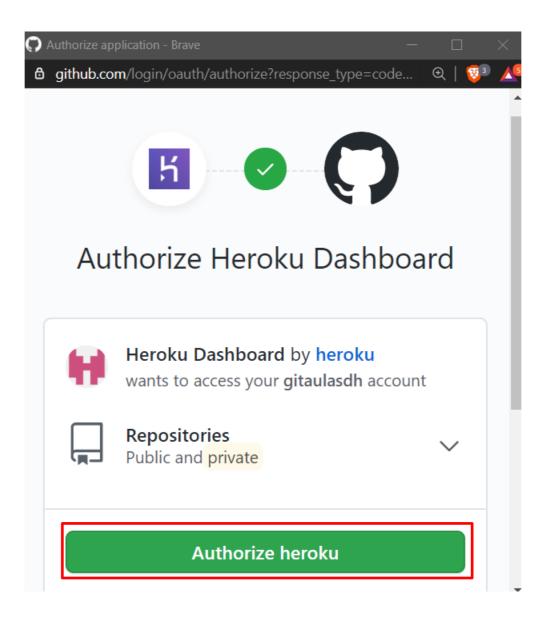
# App name webappauladh webappauladh is available Choose a region United States Add to pipeline... Create app



#### **CONECTAR O HEROKU AO GIT**

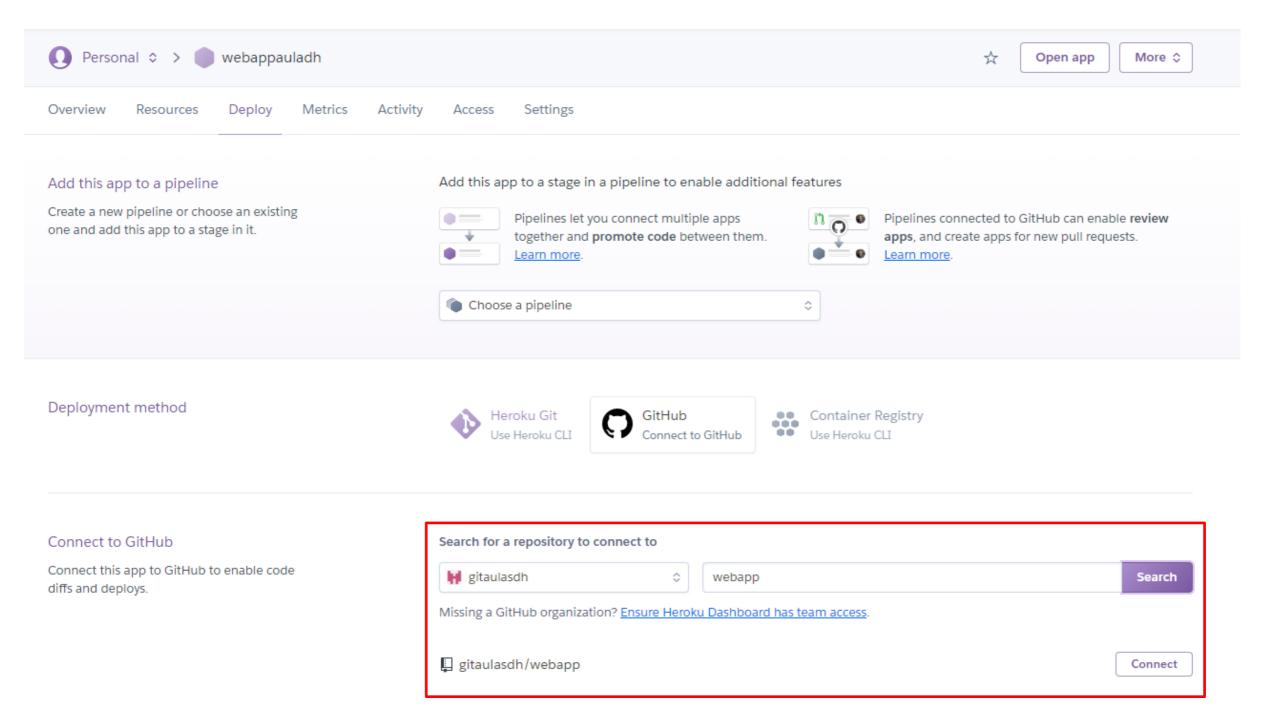


#### **AUTORIZAR A CONEXÃO**



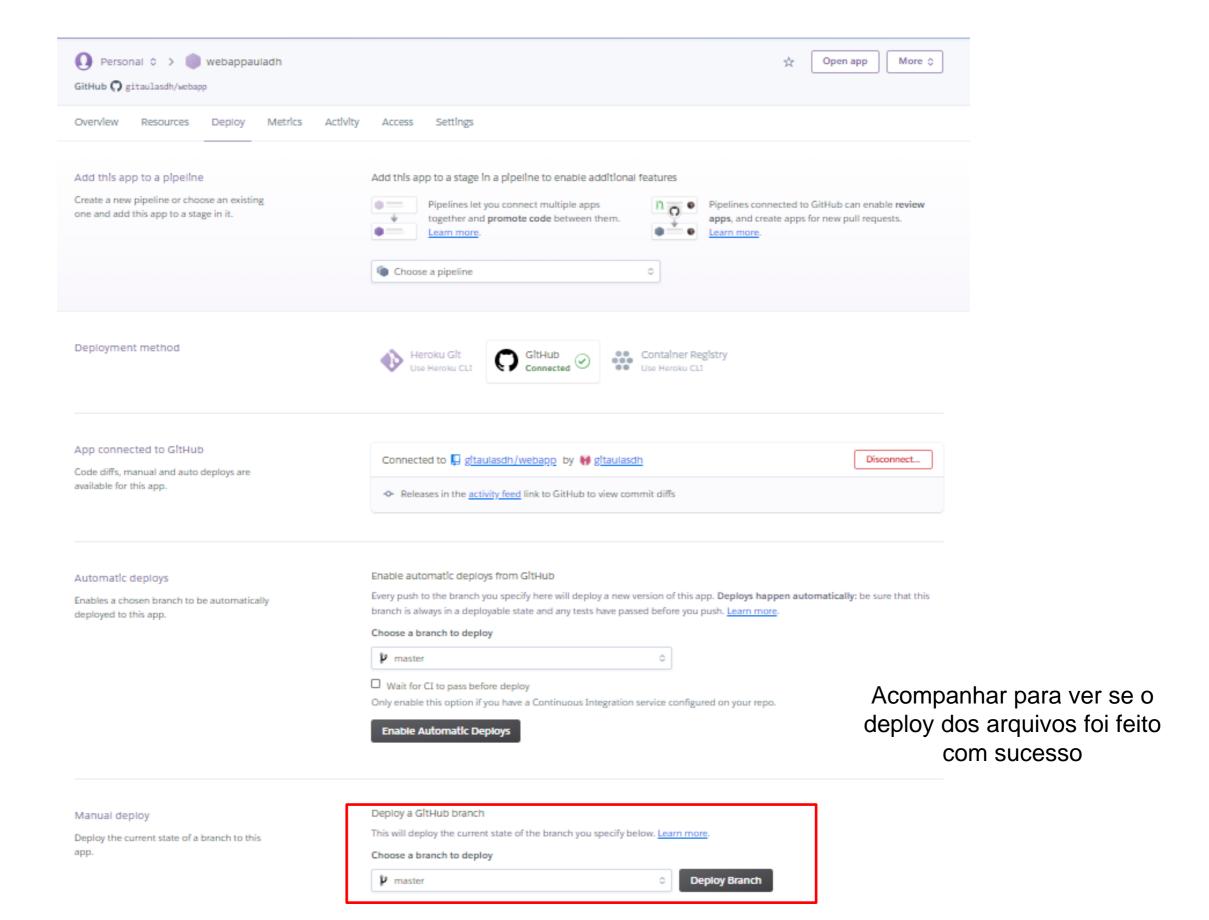


#### **INFORMAR REPO CRIADO NO GITHUB E DAR CONNECT**



Aguardar alguns segundos para que seja feita a conexão / download do repo ou dê reload na página

#### **CLIQUE EM "DEPLOY BRANCH"**

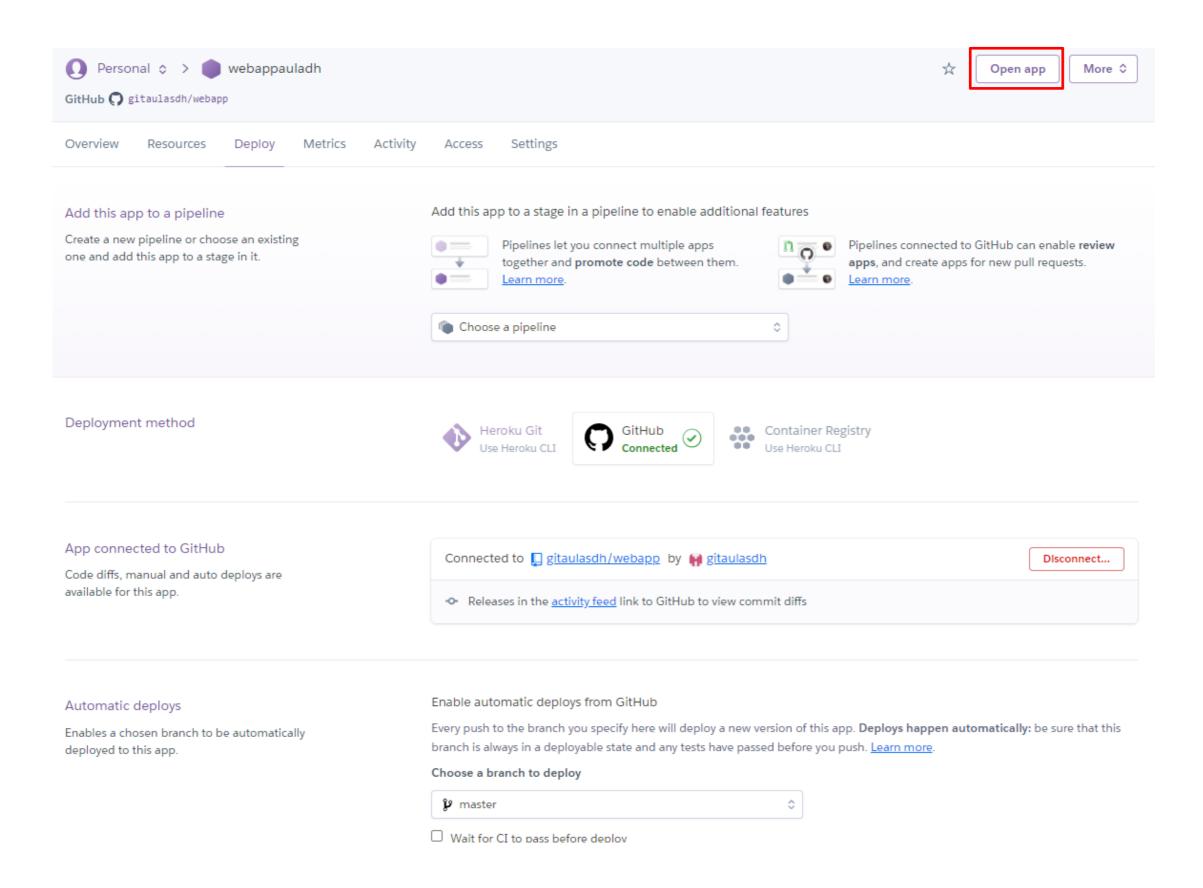




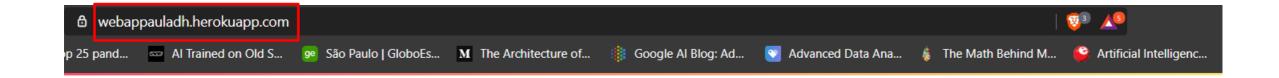
#### **CLIQUE EM "DEPLOY BRANCH"**

Receive code from GitHub	$\odot$
Build master b25299e3	⊗
Release phase	⊗
Deploy to Heroku	<b>②</b>
Your app was successfully de	oloyed.
<b>☑ View</b>	

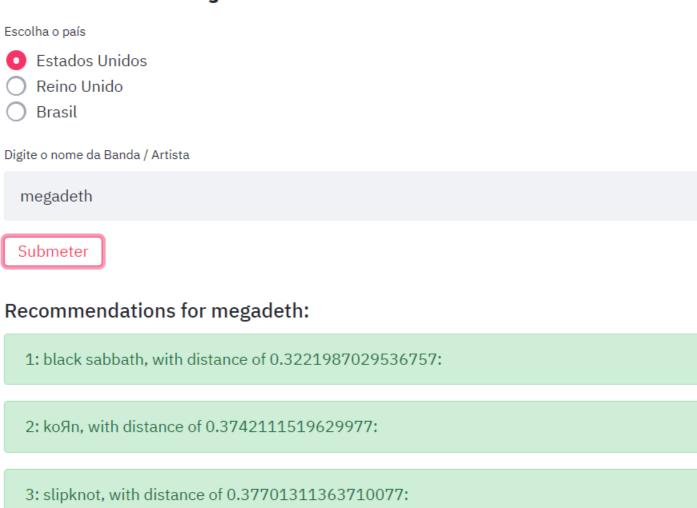
#### **CLIQUE EM "OPEN APP"**







#### Recomendação de Bandas



Procfile – indica os comandos que vão ser executados

```
1 | numpy==1.17.3
2 | pandas==1.0.5
3 | streamlit==0.62.0
4 | scipy==1.4.1
5 | fuzzywuzzy==0.18.0
6 | sklearn
7
```

**requirements.txt** – libs a serem instaladas

```
mkdir -p ~/.streamlit/

echo "\
feeting server]\n\
headless = true\n\
port = $PORT\n\
enableCORS = false\n\
n\
" > ~/.streamlit/config.toml
```

**setup.sh** – preparação e configuração do ambiente

# VAMOS COLOCAR UM WEB SERVICE EM PRODUÇÃO (NA INTERNET)



Vamos rodar o o Notebook
 titanic\_api\_heroku\_vf.ipynb
 para vermos a utilização de APIs com um
 modelo persistido com o pickle – localmente e
 no Heroku.







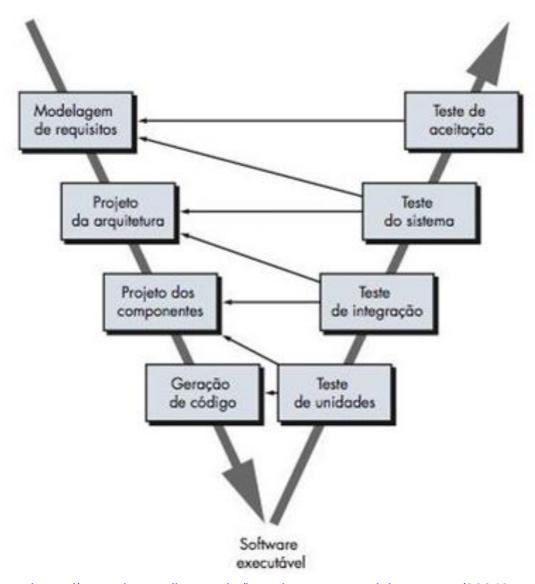
Agora vamos criar um webservice com o Flask e fazer o deploy do mesmo no Heroku.



Descompactar arquivos em webservice.zip e abrir o notebook deploy\_api\_heroku\_v1.ipynb no Jupyter.



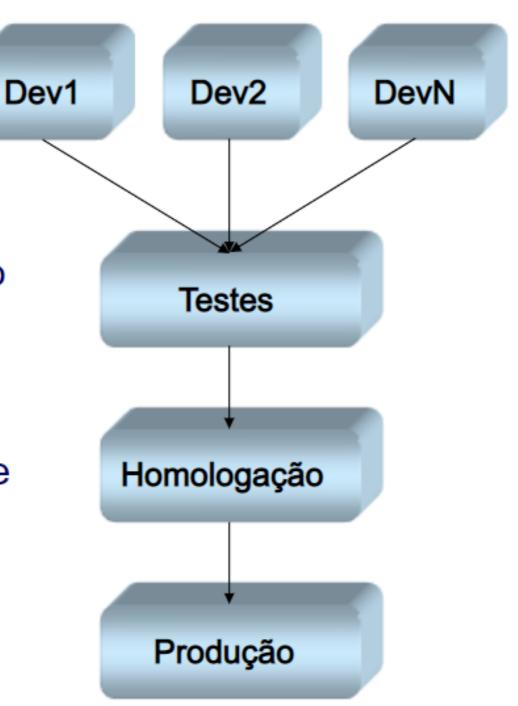
# COMO O SOFTWARE CHEGA AO AMBIENTE PRODUTIVO?

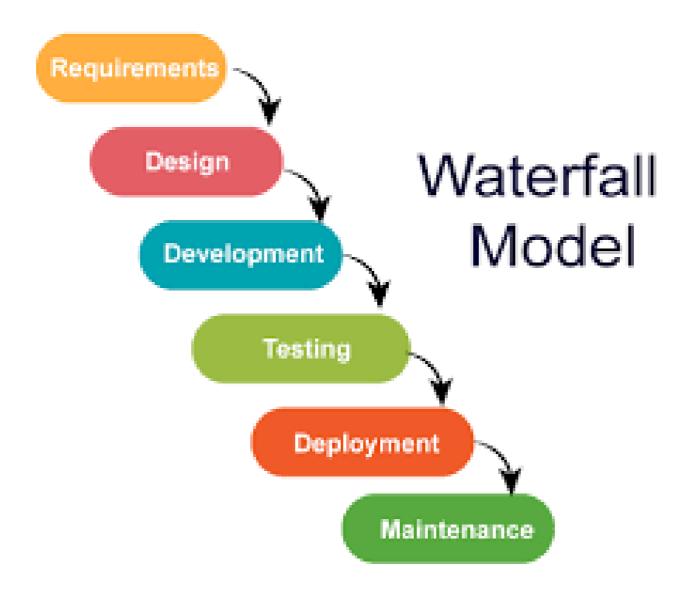


https://www.devmedia.com.br/introducao-ao-modelo-cascata/29843

Importante lembrarmos do modelo mais tradicional de desenvolvimento de software – o "V Model" para entendermos sua evolução e o estágio atual dos conceitos de entrega e desenvolvimento de software.

- Desenvolvimento
  - Estação de trabalho dos desenvolvedores
- Testes
  - Ambiente para testar a integração das unidades desenvolvidas
- Homologação
  - Ambiente similar ao de produção utilizado para realizar os testes de aceitação
- Produção
  - Ambiente real de produção da aplicação





Outra denonimação muito comum para o modelo tradicional de desenvolvimento de software é *Waterfall* ou Cascata em português.





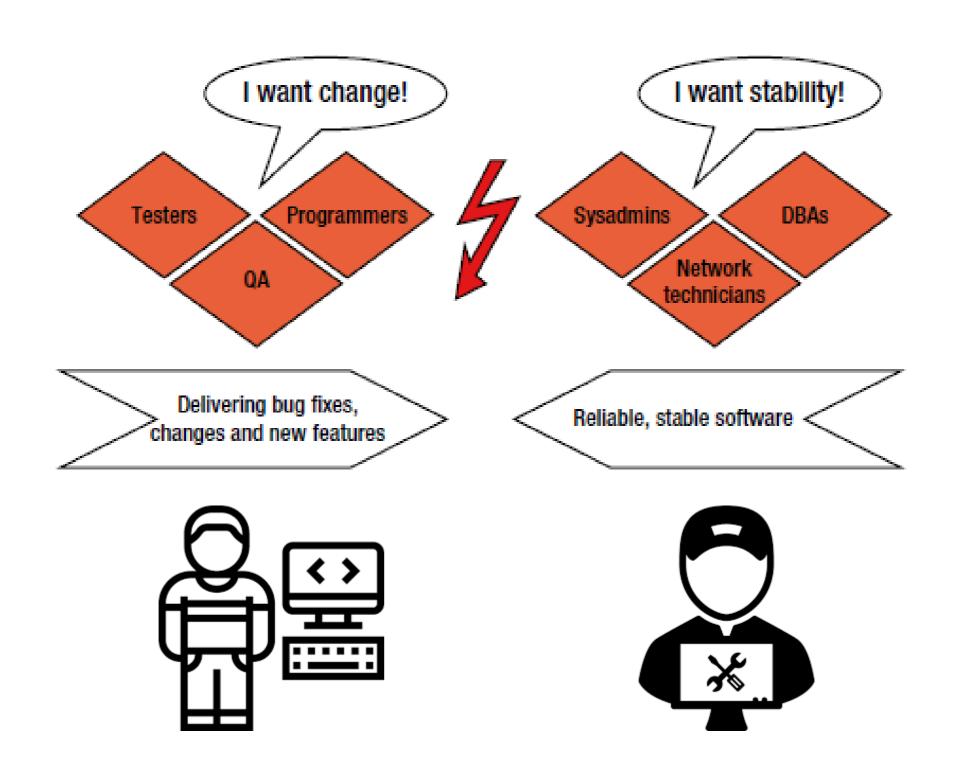








No modelo tradicional de desevolvimento o programador faz o *Build* de seu programa e entrega o executável produzido para a equipe de Operações. Esta equipe faz a *Movimentação* do programa entre os ambientes.



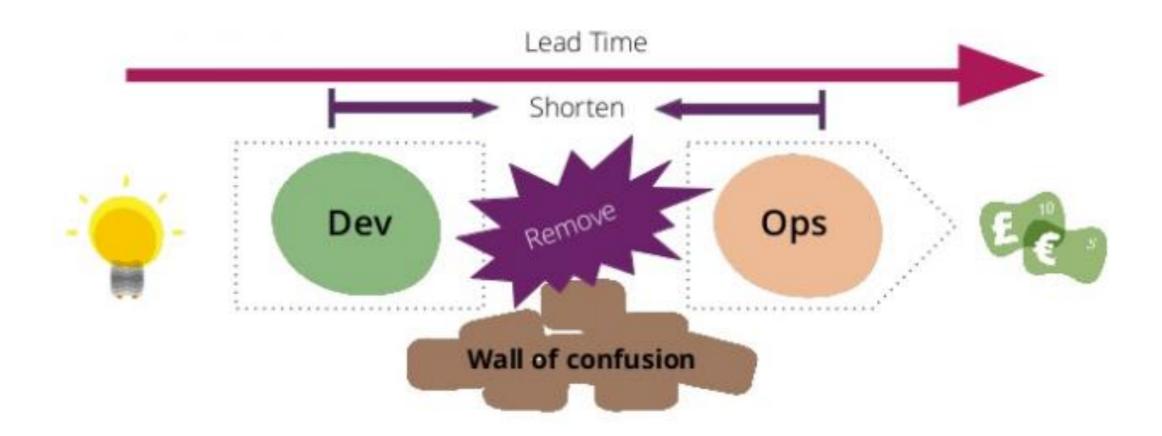


No modelo tradicional de desenvolvimento tínhamos uma divisão clara e distinta entre as equipes de **Desenvolvimento** e **Operações**. Hoje é consenso que havia entre os dois um "**Muro de Confusão**" causando uma série de problemas.

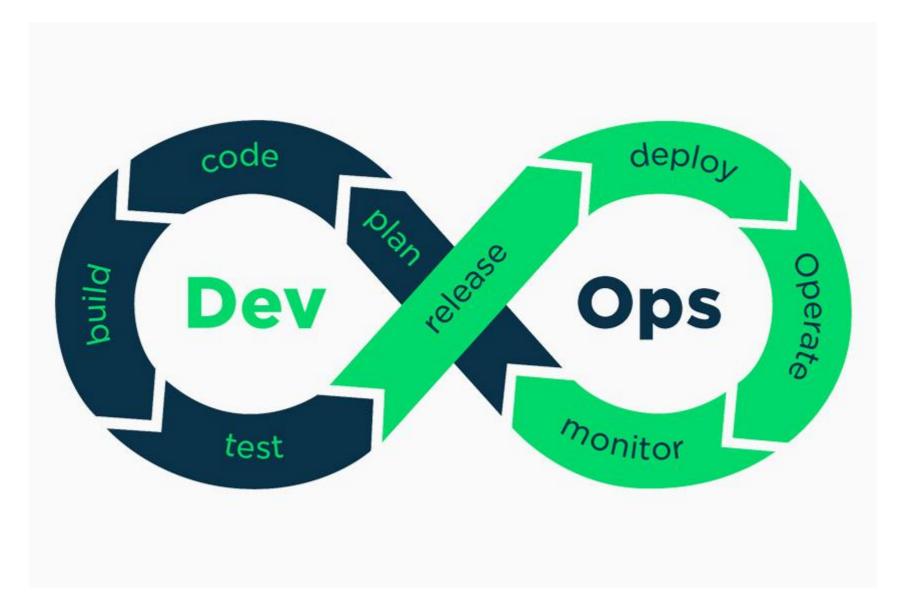


https://pt.slideshare.net/jallspaw/10-deploys-per-day-dev-and-ops-cooperation-at-flickr

Porém em 2009 John Allspaw e Paul Hammond fizeram a apresentação "10 deploys per day – Dev & Ops cooperation at Flickr" – introduzindo o conceito de DevOps.



O conceito de DevOps propõe então eliminar esta barreira entre as duas equipes – principalmente através da **Automatização** dos processos de entrega de software ao ambiente produtivo.



E junto com a automação, além da maior integração entre as equipes, a ideia é que o processo de entrega de software com valor ao cliente possa ocorrer com uma frequência bem maior – baseada em um processo iterativo.



192018 - All training materials are sole property of van Haren Publishing by and are not to be reproduced in any form or shape without written permission. **1.5** 18

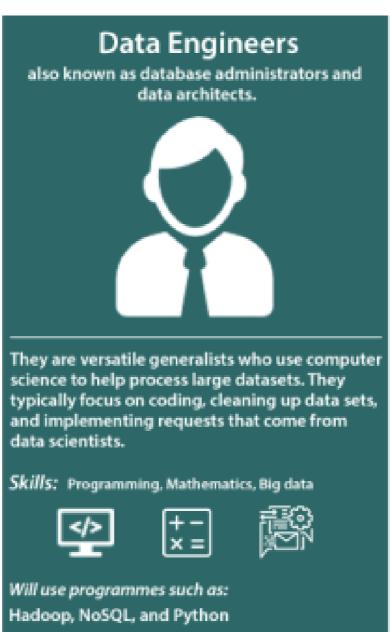
Essa nova maneira de entregar software foi impulsionada também pelo advento das metodologias ágeis (Agile) de desenvolvimento de software – que também propôs a entrega de software com valor em intervalos menores – num processo iterativo.

#### Agile Methodology



### DEV E OPS EM CIÊNCIA DE DADOS





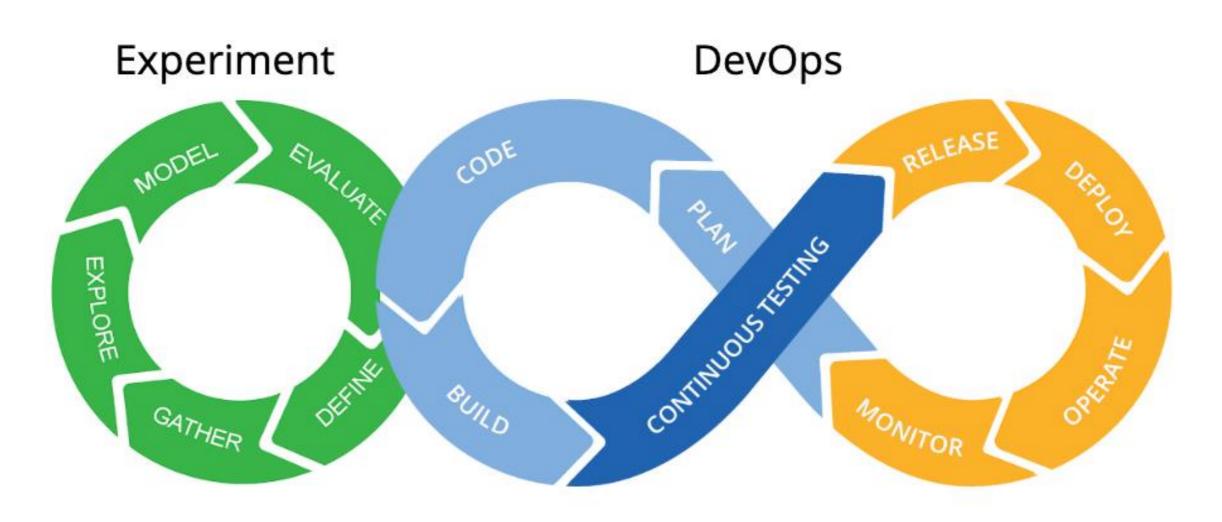


**DEV** 

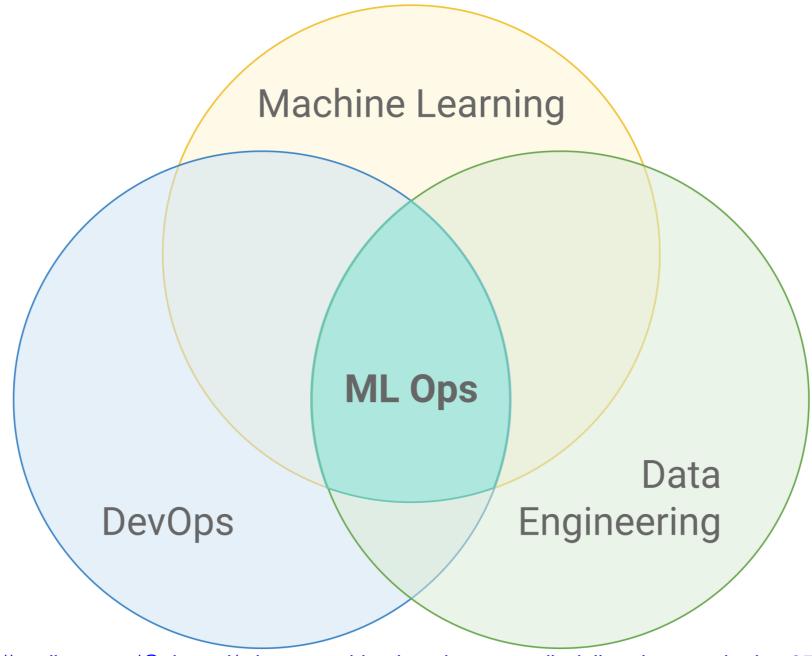
**OPS** 

"It has been said that a data scientist is someone who is better at statistics than any software engineer, and better at software engineering than any statistician"

# MACHINE LEARNING OPERATIONS ML - OPS



https://blog.jdriven.com/2019/10/machine-learning-systems-require-paradigm-shift-in-software-engineering/



https://medium.com/@cbreuel/ml-ops-machine-learning-como-disciplina-de-engenharia-a058770b93dc

O ML Ops é um conjunto de práticas que combina Machine Learning, DevOps e Engenharia de Dados, que visa implantar e manter sistemas de ML em produção de maneira confiável e eficiente.

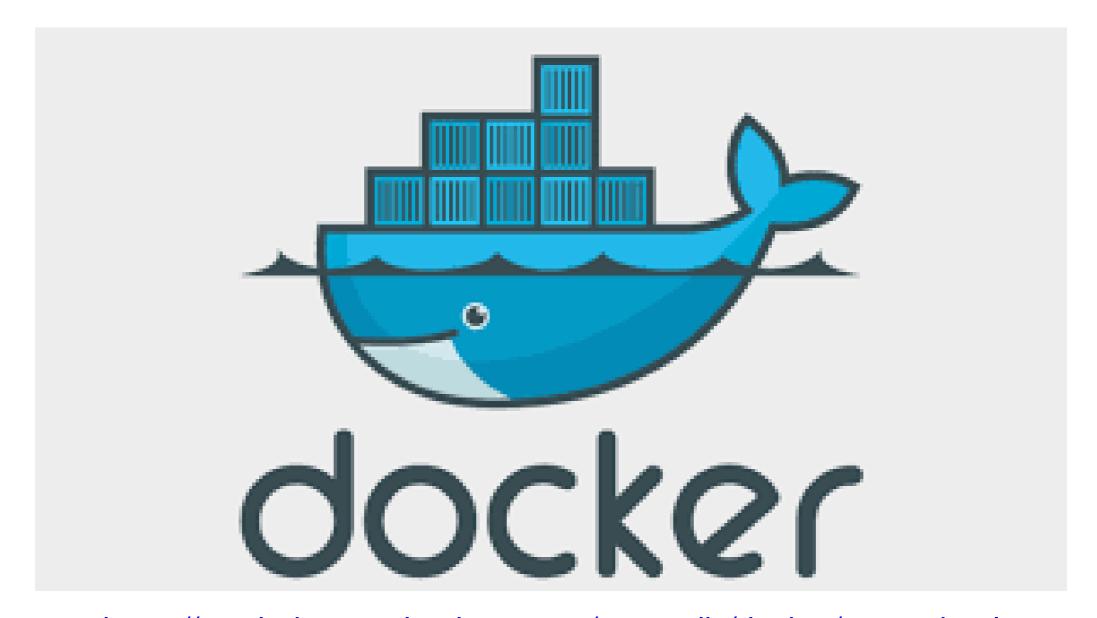
Prática	DevOps	Engenharia de Dados	ML Ops
Controle de versões	Versionamento de código	Versionamento de código Linhagem de dados	Versionamento de código + dados + modelos (conectados)
Pipeline	n/a	Pipeline de dados/ETL	Pipeline ML de treinamento, Pipeline ML de predição
Validação de comportamento	Testes unitários	Testes unitários	Validação de modelo
CI/CD	Implanta código em produção	Implanta código do pipeline de dados	Implanta código dos pipelines de ML
Validação de dados	n/a	Validação de negócio e formato	Validação estatística
Monitoramento	Baseado em SLOs	Baseado em SLOs	SLOs + monitoramento diferencial e estatístico, em fatias

https://medium.com/@cbreuel/ml-ops-machine-learning-como-disciplina-de-engenharia-a058770b93dc

Como uma diferença fundamental em relação ao modelo de DevOps observamos que em ML também precisamos fazer o deploy adicional de Dados e Modelos para funcionamento e Validação da solução preditiva.

# FERRAMENTAS ENVOLVIDAS ML - OPS

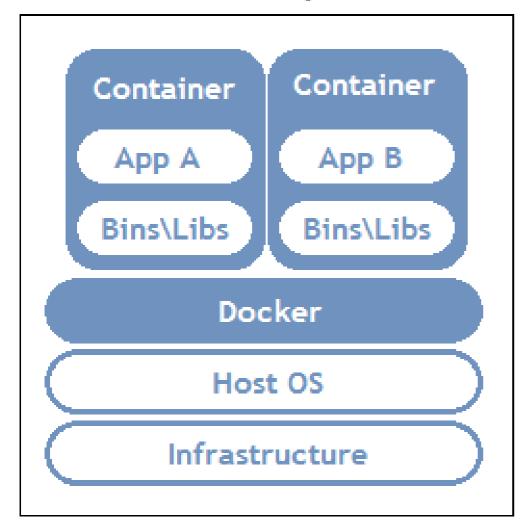
# **DOCKER**



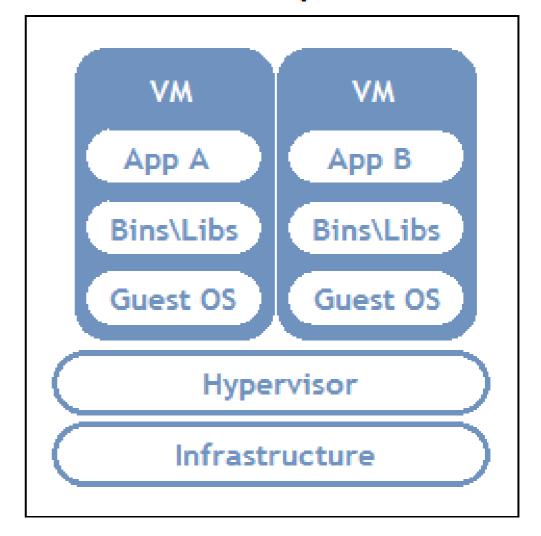
https://stack.desenvolvedor.expert/appendix/docker/oquee.html

Docker é uma plataforma aberta, criada com o objetivo de facilitar o desenvolvimento, a implantação e a execução de aplicações em ambientes isolados. Foi desenhada especialmente para disponibilizar uma aplicação da forma mais rápida possível – com a possibilidade de escalonamento horizontal quase que imediato.

#### Container Based Implementation

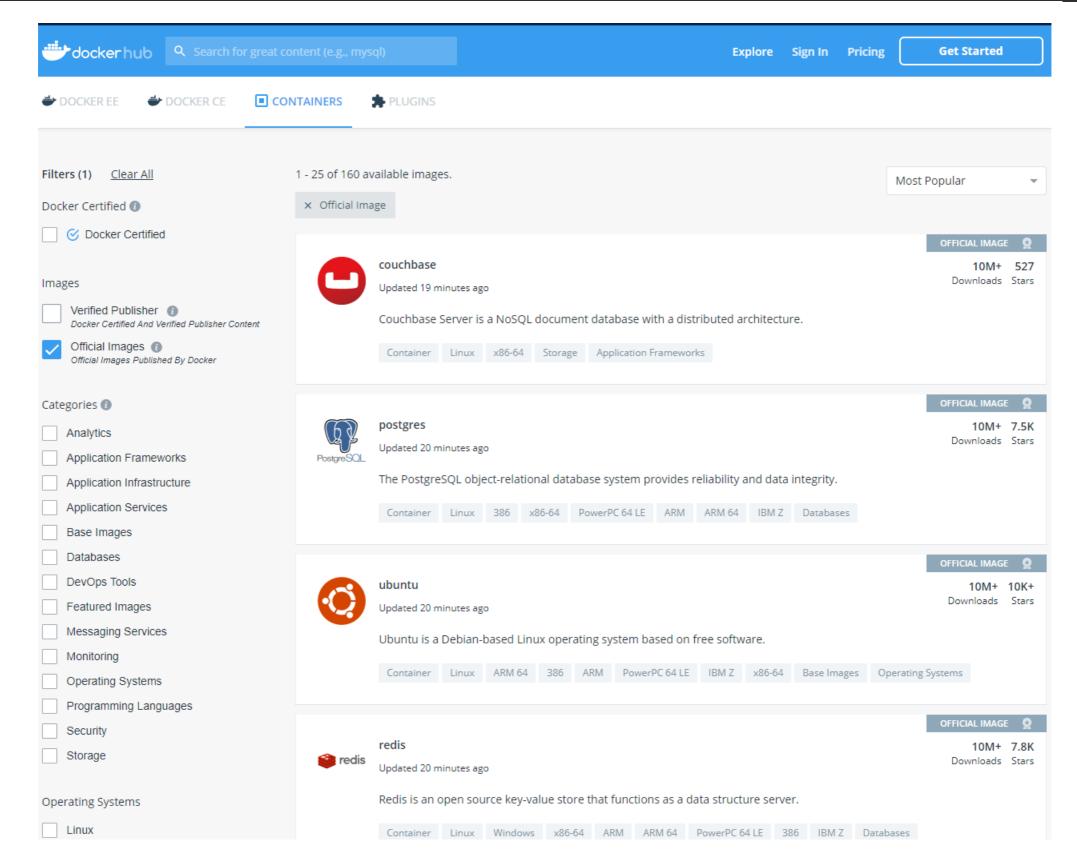


#### Virtual Machine Implementation



O Docker se diferencia por trabalhar com **CONTEINERS** que podem ser entendidos como mini-máquinas virtuais - muito leves e simples que podem ser instanciadas com diferentes imagens (bases de dados, sistemas operacionais, etc). Por serem leves e diretamente conectadas ao kernel do sistema operacional elas podem rapidamente ser criadas e destruídas, otimizando a utilização do hardware.

#### **IMAGENS DOCKER**



https://hub.docker.com/search?image\_filter=official&type=image

# **KUBERNETES**





https://www.concrete.com.br/2018/02/22/tudo-o-que-voce-precisa-saber-sobre-kubernetes/

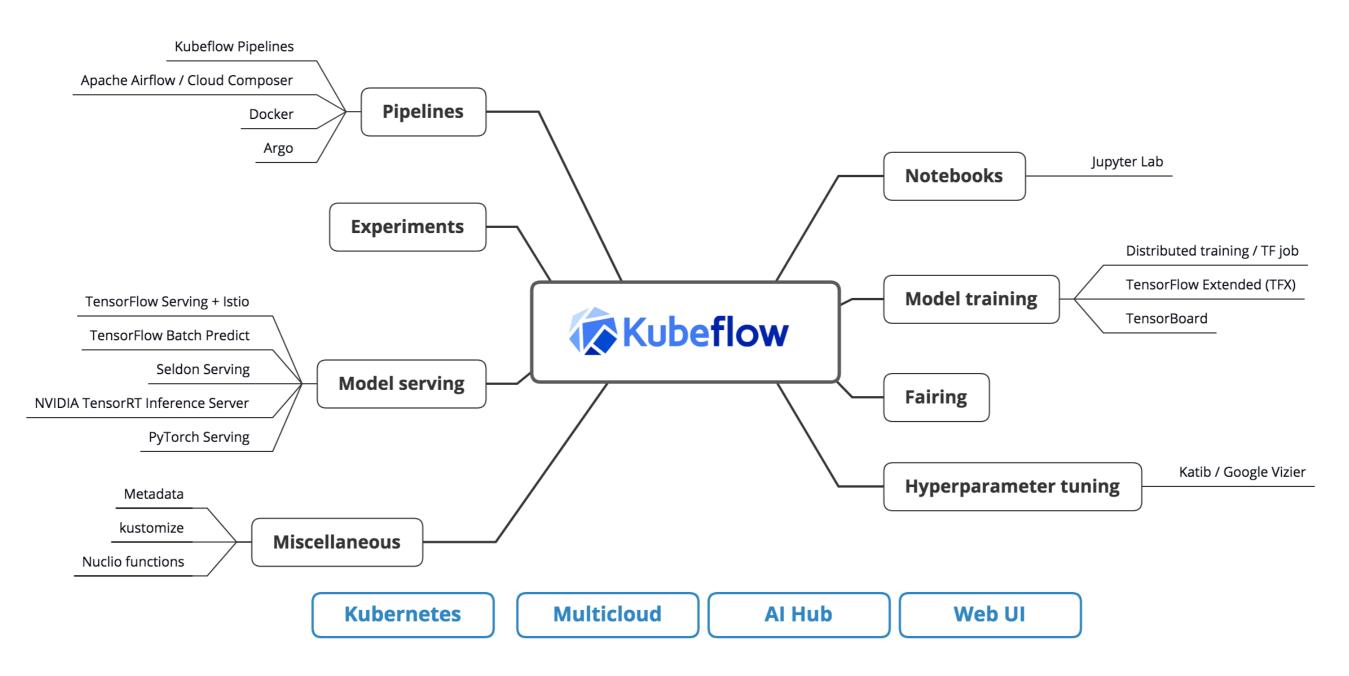
O Kubernetes é uma ferramenta que faz o **Gerenciamento de Conteiners** gerados por aplicações com o Docker.



https://www.slideshare.net/renatogroff1/docker-kubernetes-orquestrando-containers-e-escalando-rapidamente-suas-aplicaes-devops-professionals-setembro2018

Docker + Kubernetes: Orquestrando containers e escalando rapidamente suas aplicações - DevOps Professionals - Setembro-2018

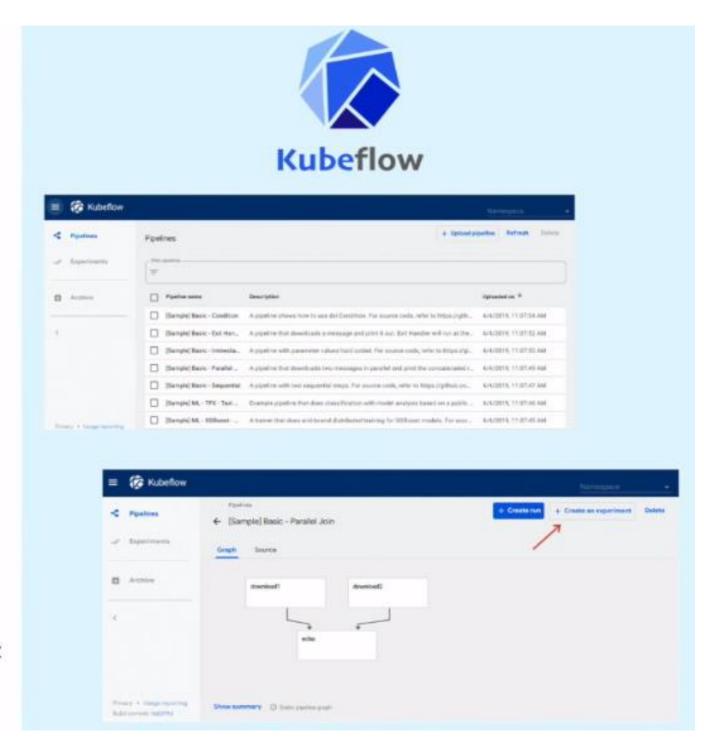
# KUBEFLOW



# Kubeflow Pipelines

Kubeflow Pipelines is a platform for building and deploying portable, scalable machine learning (ML) workflows based on Docker containers.

- End-to-end orchestration: enabling and simplifying the orchestration of machine learning pipelines.
- Easy experimentation: making it easy for you to try numerous ideas and techniques and manage your various trials/experiments.
- Easy re-use: enabling you to re-use components and pipelines to quickly create end-to-end solutions without having to rebuild each time.



# Kubeflow Pipelines

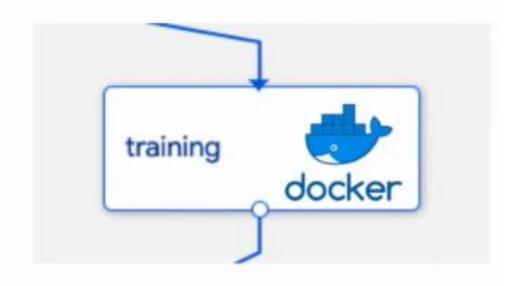
Two key takeaways : A Pipeline and a Pipeline Component

A *pipeline* is a description of a machine learning (ML) workflow, including all of the components of the workflow and how they work together.

[Sample] ML - TFX - Taxi Tip Prediction Model Trainer Source validation preprocess training analysis prediction deploy confusion-matrix roc

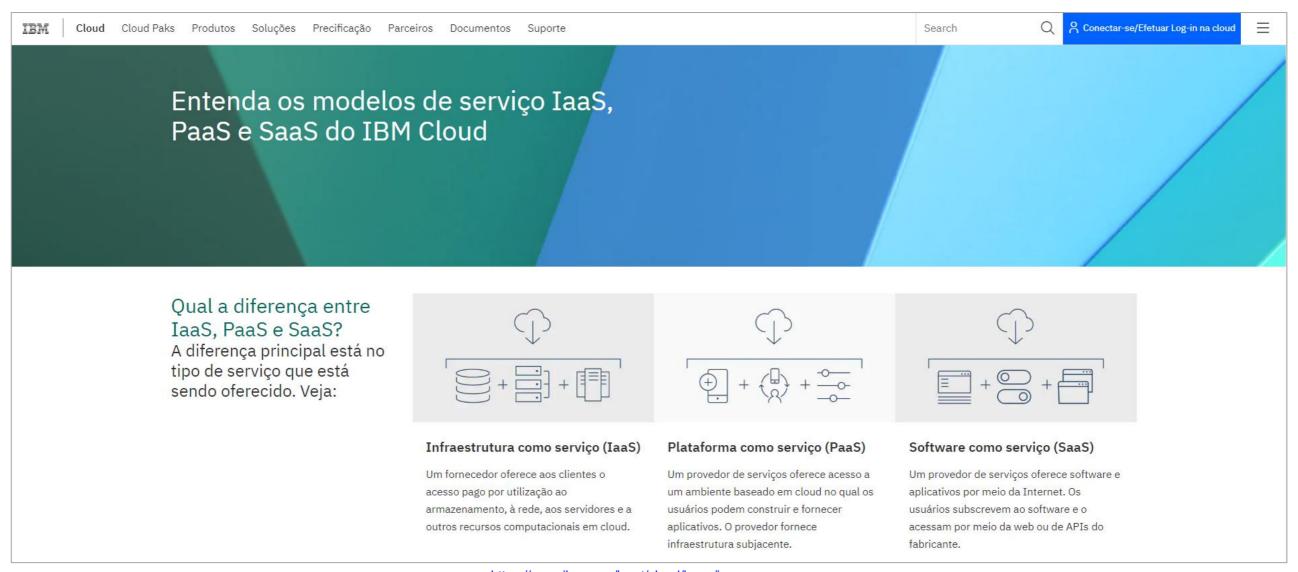
# Kubeflow Pipelines

Each pipeline component is a container that contains a program to perform the task required for that particular step of your workflow.

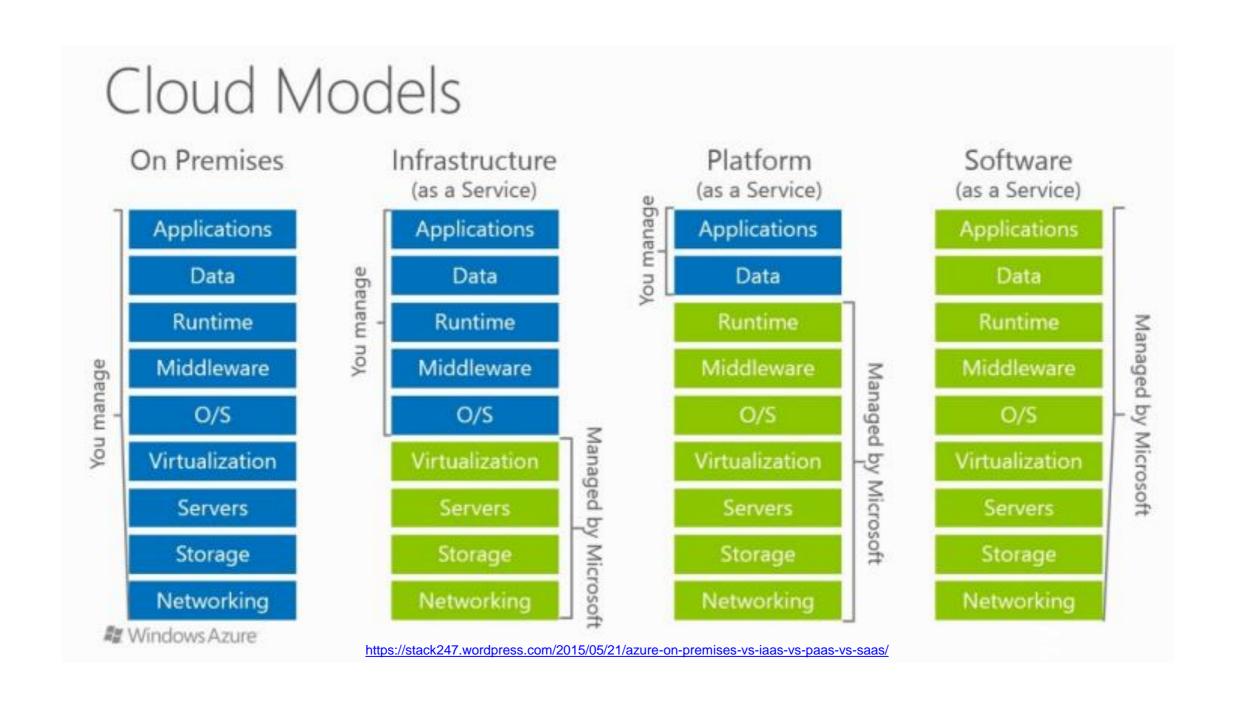


# MODELOS NA CLOUD

#### On Premise x laaS x PaaS x SaaS



https://www.ibm.com/br-pt/cloud/learn/iaas-paas-saas















Amazon SageMaker



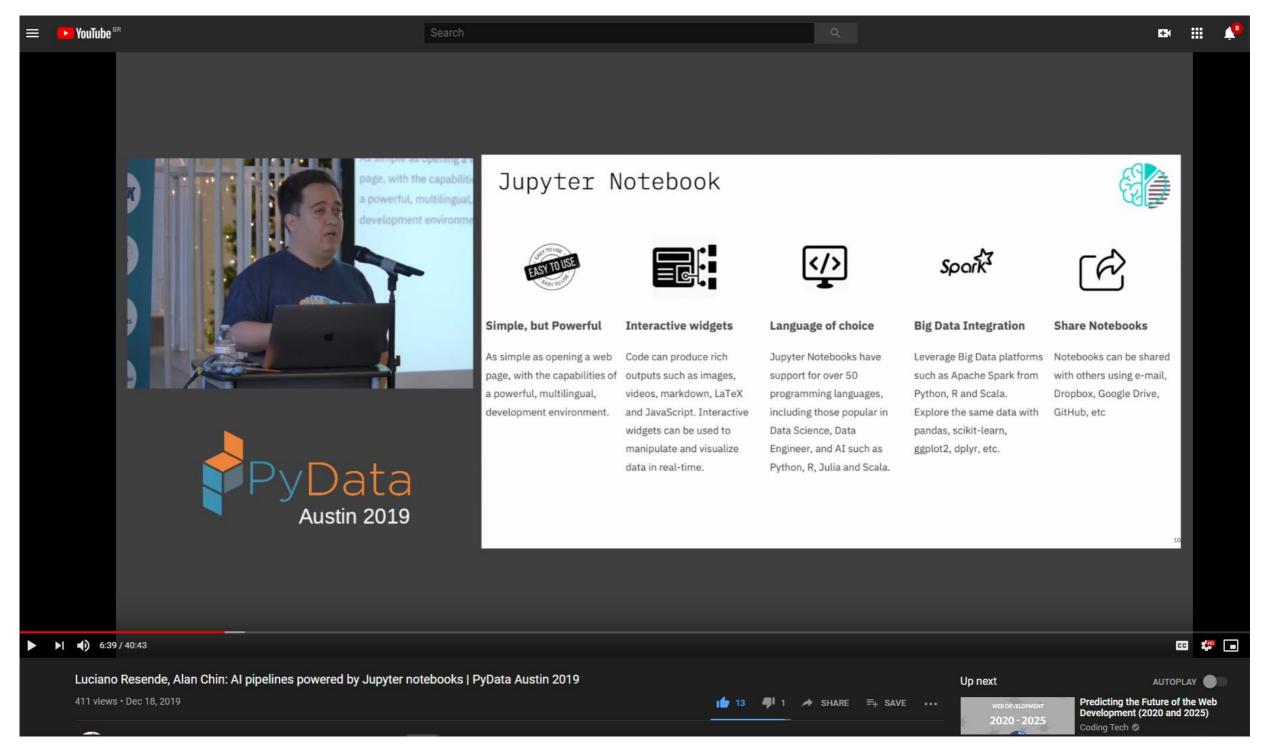




# JUPYTER NOTEBOOKS EM PRODUÇÃO

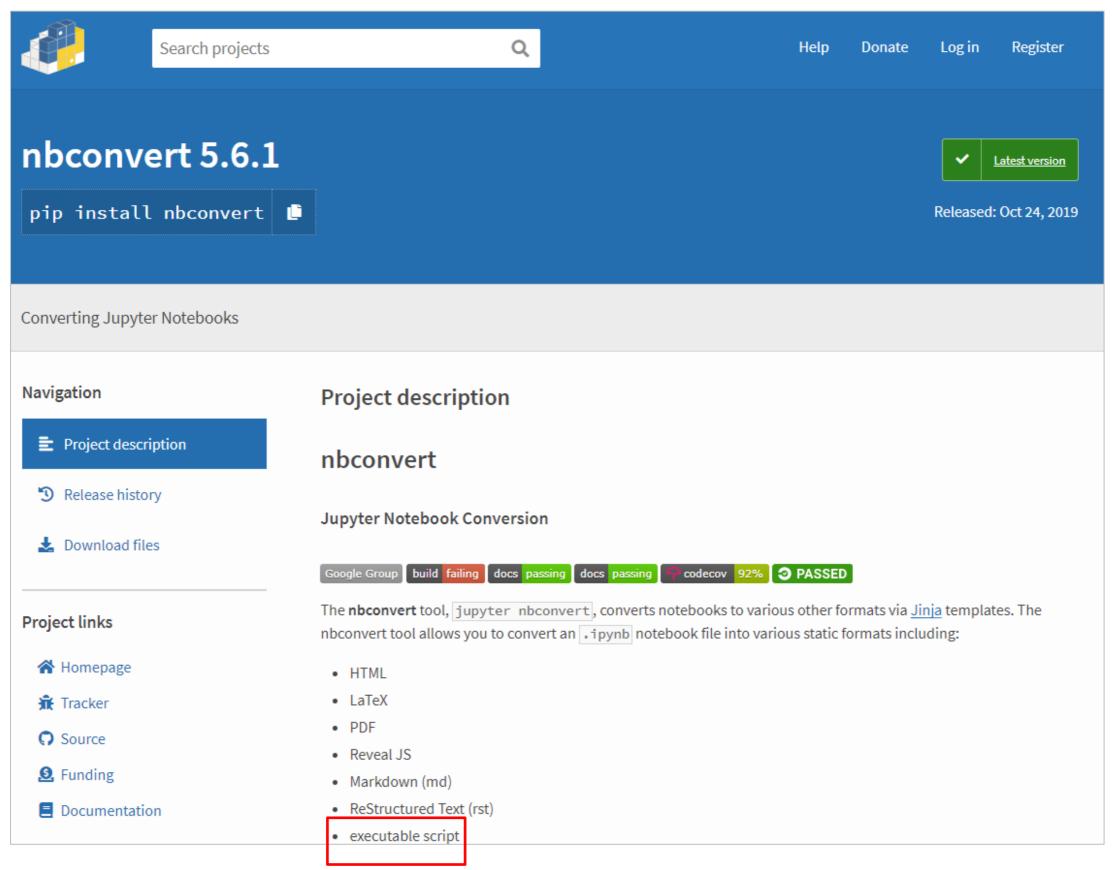


## JUPYTER NOTEBOOKS EM PRODUÇÃO!



https://youtu.be/XJAx9dS0k7I

### **NBCONVERT**



https://pypi.org/project/nbconvert/

# Notebook Pipelines using NBConvert

Jupyter NBConvert enables executing and converting notebooks to different file formats.

### Advantages

- Support notebook chaining
- Convert results to immutable formats
   Limitations
- No support for parameters

#### **Jupyter NBConvert**

https://nbconvert.readthedocs.io/en/latest/



\$ pip install nbconvert

\$ jupyter nbconvert -- to html -- execute overview\_with\_run.ipynb

[NbConvertApp] Converting notebook overview\_with\_run.ipynb to html

[NbConvertApp] Executing notebook with kernel; python3

[NbConvertApp] Writing 300558 bytes to overview\_with\_run.html

\$ open overview\_with\_run.html

## Papermill

Papermill is an open source tool contributed by Netflix which enables parameterizing, executing, and analyzing Jupyter Notebooks.

#### Papermill lets you:

- Parameterize notebooks
- Execute notebooks



# **Digital**House>

# **DATA SCIENCE**

Machine Learning – Modelos em Produção